
AGRIPREDICT

Système de recommandation de cultures
par fusion des données climatiques et pédologiques

Rapport Technique

Projet de Certification en Intelligence Artificielle

Équipe du Projet :

Ilimane GNING
ABDOU KHADRE DIALLO
FATOU FAYE

Supervision : Force N Sénégal

Date : 2 août 2026

Dans le cadre des formations données par Force N Sénégal

Table des matières

Résumé	3
1 INTRODUCTION	3
1.1 Contexte et Problématique	3
1.2 Objectifs	3
1.3 Organisation du Rapport	3
2 DONNÉES UTILISÉES	4
2.1 Présentation du Dataset	4
2.2 Statistiques Descriptives	4
2.3 Qualité des Données	4
2.4 Distribution des Cultures	4
3 MÉTHODOLOGIE	5
3.1 Pipeline Général	5
3.2 Prétraitement des Données	5
3.3 Modèles Comparés	5
3.4 Métriques d'Évaluation	6
4 RÉSULTATS	7
4.1 Comparaison des Modèles	7
4.2 Analyse des Performances	7
4.3 Analyse des Erreurs	7
5 INTERFACE UTILISATEUR	8
5.1 Présentation	8
5.2 Fonctionnalités	8
5.3 Accès	8
5.4 Technologies Utilisées	8
5.5 Dépendances	8
6 LIMITES ET PERSPECTIVES	9
6.1 Limites Actuelles	9
6.2 Perspectives d'Amélioration	9

7	CONCLUSION	10
7.1	Synthèse des Réalisations	10
7.2	Impact Potentiel	10
7.3	Recommandations	10
8	RÉFÉRENCES	11
9	ANNEXES	12
9.1	Environnement Technique	12
9.2	Mapping des Cultures	12
9.3	Remerciements	12

Résumé

AgriPredict est un système de recommandation de cultures basé sur l'intelligence artificielle, développé dans le cadre des formations de **Force N Sénégal**. Face au changement climatique qui rend les cycles agricoles imprévisibles, cet outil aide les conseillers agricoles à orienter les agriculteurs vers les cultures adaptées à leurs conditions de sol et climatiques.

Méthodologie : Dataset Kaggle (2200 échantillons, 22 cultures, 7 caractéristiques). Comparaison de 4 modèles : Régression Logistique, Arbre de Décision, Random Forest, XGBoost.

Résultats : Random Forest (99.55% d'accuracy) avec interface Gradio interactive.

Mots-clés : Intelligence Artificielle, Agriculture, Random Forest, Recommandation de Cultures, NPK, Sécurité Alimentaire.

1 INTRODUCTION

1.1 Contexte et Problématique

Le changement climatique représente aujourd'hui l'un des défis majeurs pour l'agriculture mondiale. Les cycles agricoles deviennent de plus en plus imprévisibles, affectant directement la production alimentaire et menaçant la sécurité alimentaire des populations.

Au Sénégal, l'agriculture constitue un pilier essentiel de l'économie et de la sécurité alimentaire. Les agriculteurs font face à des conditions climatiques de plus en plus erratiques : sécheresses prolongées, pluies torrentielles hors saison, variations de températures. Ces phénomènes rendent difficile le choix des cultures à planter.

C'est dans ce contexte que le Ministère de l'Agriculture a exprimé le besoin de disposer d'une application permettant d'orienter les agriculteurs vers les cultures les plus prometteuses en fonction des conditions de leur sol et des prévisions météorologiques.

1.2 Objectifs

1. Nettoyer et fusionner des données hétérogènes (climat + sol)
2. Entraîner des modèles de classification robustes
3. Évaluer les performances des modèles
4. Créer une interface de simulation interactive
5. Présenter les limites et pistes d'amélioration

1.3 Organisation du Rapport

Ce rapport présente successivement les données utilisées, la méthodologie adoptée, les résultats obtenus, l'interface utilisateur, les limites du système et les perspectives d'amélioration.

2 DONNÉES UTILISÉES

2.1 Présentation du Dataset

Le projet s'appuie sur le *Crop Recommendation Dataset* disponible sur Kaggle, sous licence CC0 (Domaine Public).

TABLE 1 – Description du Dataset

Élément	Description
Nom	Crop Recommendation Dataset
Source	Kaggle
Lignes	2 200
Variables	N, P, K, température, humidité, pH, pluviométrie
Cible	22 types de cultures
Licence	CC0 (Domaine Public)

2.2 Statistiques Descriptives

TABLE 2 – Statistiques des Variables

Variable	Moyenne	Écart-type	Min	Max
Azote (N)	50.55	36.91	0	140
Phosphore (P)	53.36	32.98	0	145
Potassium (K)	48.15	50.64	0	205
Température	25.62	5.06	15	35
Humidité	71.48	22.26	40	90
pH	6.47	0.77	4.5	8.5
Pluviométrie	103.46	54.95	50	300

2.3 Qualité des Données

- **Valeurs manquantes** : 0%
- **Équilibre des classes** : 100 échantillons par culture (22 classes)
- **Outliers** : Présents mais conservés pour leur représentativité agronomique

2.4 Distribution des Cultures

Le dataset est parfaitement équilibré avec 22 cultures différentes :

TABLE 3 – Liste des 22 Cultures

Apple	Banana	Blackgram	Chickpea
Coconut	Coffee	Cotton	Grapes
Jute	Kidneybeans	Lentil	Maize
Mango	Mothbeans	Mungbean	Muskmelon
Orange	Papaya	Pigeonpeas	Pomegranate
Rice	Watermelon		

3 MÉTHODOLOGIE

3.1 Pipeline Général

La méthodologie suit un pipeline standard en intelligence artificielle :

1. **Exploration (EDA)** : Visualisation des distributions et corrélations
2. **Prétraitement** : Encodage des labels, normalisation des données
3. **Split** : 80% Train / 20% Test (stratifié)
4. **Modélisation** : 4 modèles comparés
5. **Évaluation** : Accuracy, F1-Score, Cross-Validation (CV=5)

3.2 Prétraitement des Données

Encodage des Labels :

Listing 1 – Encodage

```
from sklearn.preprocessing import LabelEncoder
label_encoder = LabelEncoder()
y_encoded = label_encoder.fit_transform(y)
```

Normalisation (StandardScaler) :

Listing 2 – Normalisation

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

Division Train/Test :

Listing 3 – Split

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(
    X_scaled, y_encoded, test_size=0.2,
    random_state=42, stratify=y_encoded
)
```

3.3 Modèles Comparés

TABLE 4 – Modèles Utilisés

Modèle	Type	Rôle
Régression Logistique	Linéaire	Baseline
Arbre de Décision	Non-linéaire	Interprétable
Random Forest	Ensemble	Modèle principal
XGBoost	Boosting	Modèle avancé

3.4 Métriques d'Évaluation

- **Accuracy** : Pourcentage de prédictions correctes
- **F1-Score (macro)** : Moyenne harmonique précision/rappel
- **Cross-Validation (CV=5)** : Validation croisée à 5 folds

4 RÉSULTATS

4.1 Comparaison des Modèles

TABLE 5 – Performances des Modèles

Modèle	Accuracy	F1-Score	CV Mean	CV Std
Random Forest	99.55%	99.55%	99.32%	0.0043
XGBoost	99.09%	99.08%	98.92%	0.0049
Decision Tree	97.95%	97.94%	98.47%	0.0071
Logistic Regression	97.27%	97.25%	96.76%	0.0113

4.2 Analyse des Performances

Random Forest - Meilleur Modèle

- **Accuracy** : 99.55% (seulement 2 erreurs sur 440 tests)
- **F1-Score** : 99.55% (équilibre parfait)
- **CV Mean** : 99.32% avec écart-type très faible (0.0043)

Pourquoi Random Forest domine :

1. Gestion des relations non-linéaires complexes
2. Robustesse aux outliers (données agricoles)
3. Détection des combinaisons optimales de paramètres
4. Réduction de la variance (modèle ensembliste)

4.3 Analyse des Erreurs

Seulement **2 erreurs sur 440 prédictions** (0.45%) :

TABLE 6 – Erreurs du Modèle

Vérité Terrain	Prédiction	Raison
Blackgram (Pois noir)	Maize (Maïs)	Besoins en nutriments proches
Rice (Riz)	Jute (Jute)	Conditions humides similaires

5 INTERFACE UTILISATEUR

5.1 Présentation

L'interface a été développée avec **Gradio**, offrant une expérience interactive et intuitive.

5.2 Fonctionnalités

- 7 sliders interactifs (N, P, K, température, humidité, pH, pluviométrie)
- Bouton "Prédire" pour lancer l'analyse
- Affichage de la culture recommandée
- Niveau de confiance (0-100%)
- Top 5 cultures avec probabilités
- Graphique à barres des probabilités
- Exemples préchargés pour test rapide
- Interface responsive (PC, mobile, tablette)

5.3 Accès

[Accéder à AgriPredict](#)

5.4 Technologies Utilisées

- **Entraînement** : Google Colab Free
- **Interface** : Gradio 4.0+

5.5 Dépendances

Listing 4 – requirements.txt

```
gradio, numpy, pandas, matplotlib, seaborn
scikit-learn, xgboost, joblib
```

6 LIMITES ET PERSPECTIVES

6.1 Limites Actuelles

Limites Techniques :

- Dataset limité à 22 cultures
- Absence de données temporelles (saisonnalité)
- Pas de validation agronomique externe

Limites Éthiques :

- Biais géographique potentiel
- Pas de validation par des experts agronomes
- Ne doit pas être utilisé pour des décisions financières sans validation

6.2 Perspectives d'Amélioration

Court Terme :

- Validation agronomique experte
- Intégration de données locales (Sénégal)
- Développement d'une version mobile

Moyen Terme :

- Intégration de données satellitaires
- Prédiction multi-saisonnières
- Recommandations de fertilisation

Long Terme :

- Modèles de Deep Learning
- Intégration IoT (capteurs connectés)
- Plateforme collaborative agricole

7 CONCLUSION

7.1 Synthèse des Réalisations

- **Dataset** : 2 200 échantillons, 22 cultures, 7 caractéristiques
- **Meilleur modèle** : Random Forest avec 99.55% d'accuracy
- **Interface** : Gradio interactive et déployée
- **Impact** : Outil d'aide à la décision pour l'agriculture

7.2 Impact Potentiel

Pour les Agriculteurs :

- Décisions éclairées sur le choix des cultures
- Réduction des risques d'échec
- Optimisation des rendements
- Adaptation au changement climatique

Pour les Conseillers Agricoles :

- Outil d'aide à la décision fiable
- Recommandations basées sur des données scientifiques
- Interface simple et intuitive

Pour les Politiques Agricoles :

- Meilleure planification des productions
- Sécurité alimentaire renforcée

7.3 Recommandations

1. Validation agronomique avant déploiement généralisé
2. Formation des utilisateurs pour une utilisation optimale
3. Mise à jour continue du modèle avec nouvelles données
4. Intégration avec les systèmes d'information agricole existants

Ensemble pour une agriculture intelligente !

8 RÉFÉRENCES

1. Kaggle. (2024). *Crop Recommendation Dataset*. <https://www.kaggle.com/datasets/atharvaingle/crop-recommendation-dataset>
2. Scikit-learn Documentation. (2024). *Random Forest Classifier*. <https://scikit-learn.org/>
3. Chen, T., & Guestrin, C. (2016). *XGBoost : A Scalable Tree Boosting System*. Proceedings of the 22nd ACM SIGKDD.
4. FAO. (2023). *Facteurs de rendement agricole*. Organisation des Nations Unies.
5. Gradio Documentation. (2024). *Building ML Demos*. <https://gradio.app/>
6. Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5-32.

9 ANNEXES

9.1 Environnement Technique

Outil	Version
Python	3.10+
scikit-learn	1.2+
xgboost	1.7+
gradio	4.0+
numpy	1.24+
pandas	2.0+
matplotlib	3.7+
seaborn	0.12+
joblib	1.2+

9.2 Mapping des Cultures

Code	Culture	Code	Culture
0	Apple	11	Maize
1	Banana	12	Mango
2	Blackgram	13	Mothbeans
3	Chickpea	14	Mungbean
4	Coconut	15	Muskmelon
5	Coffee	16	Orange
6	Cotton	17	Papaya
7	Grapes	18	Pigeonpeas
8	Jute	19	Pomegranate
9	Kidneybeans	20	Rice
10	Lentil	21	Watermelon

9.3 Remerciements

L'équipe d'AgriPredict remercie chaleureusement :

- **Force N Sénégal** pour la formation, l'accompagnement et le cadre d'apprentissage
- **Le Ministère de l'Agriculture** pour l'expression du besoin
- **La communauté open-source** pour les outils mis à disposition
- **Kaggle** pour le dataset



Force N Sénégal

Former pour transformer